Examen 06 - Simulacro 1

1. Una aseguradora utiliza sus datos de conducción para ajustar las primas de sus propios clientes. ¿Qué combinación describe mejor el caso?

A. in → out y venta de datos de máquinas.
B. in → in y personalización de precios.
C. out → in y monitorización remota.
D. create → out y venta de conocimiento a terceros.

2. Un equipo recopila diez millones de respuestas voluntarias de usuarios de una aplicación y las utiliza para describir a toda la población. ¿Qué afirmación es más adecuada?

A. El volumen compensa cualquier sesgo de selección.
B. Si las respuestas están bien registradas, la muestra es representativa.
C. Solo debe comprobarse si existen respuestas duplicadas.
D. Puede haber sesgo aunque los registros sean numerosos y precisos.

3. ¿Qué actividad pertenece principalmente al modelado en CRISP-DM?

A. Elegir una técnica, establecer sus parámetros y diseñar cómo se probará.
B. Decidir si los resultados justifican cambiar la política comercial.
C. Planificar el mantenimiento del sistema implantado.
D. Identificar qué decisión de negocio se quiere mejorar.

4. Una empresa consulta las ventas por producto y mes. Después solicita totales por categoría y trimestre. Ha realizado:

A. Drill-down en producto y roll-up en tiempo.
B. Roll-up en producto y drill-down en tiempo.
C. Roll-up en ambas dimensiones.
D. Una tarea de asociación entre productos y fechas.

5. Disponemos de una variable «tipo de contrato» con cuatro categorías sin orden inherente. Para un método que utiliza distancias, ¿qué opción evita introducir directamente un orden numérico artificial?

A. Asignar los códigos 1, 2, 3 y 4.
B. Crear indicadores binarios para las categorías.
C. Ordenar las categorías alfabéticamente y numerarlas.
D. Sustituir cada categoría por su posición en la tabla.

6. Un algoritmo genera predicciones precisas, pero pequeñas modificaciones deliberadas de las entradas provocan decisiones perjudiciales. El problema afecta especialmente a:

A. La representatividad del repositorio.
B. La estructura multidimensional.
C. La inteligibilidad de las reglas.
D. La robustez frente a manipulaciones adversarias.

7. ¿Qué situación justifica mejor utilizar un log durante la extracción?

A. Identificar los registros que han cambiado desde la última ejecución.
B. Convertir categorías nominales en columnas binarias.
C. Seleccionar atributos según su relación con el objetivo.
D. Sustituir los valores ausentes de una columna.

8. Una universidad elige al azar estudiantes dentro de cada titulación. Otra elige al azar titulaciones y encuesta a todos sus estudiantes. Utilizan, respectivamente:

A. Muestreo por grupos y estratificado.
B. Muestreo aleatorio simple y exhaustivo.
C. Muestreo estratificado y por grupos.
D. Muestreo estratificado y aleatorio simple.

9. Un modelo presenta un error global bajo, pero sus errores son mucho mayores en un grupo protegido. ¿Qué conclusión es correcta?

A. La precisión global demuestra que el modelo es equitativo.
B. Debe revisarse la equidad, aunque el rendimiento global sea bueno.
C. El problema se limita a que el modelo es poco comprensible.
D. Basta con ocultar la pertenencia al grupo en los informes finales.

10. Una empresa necesita responder una única pregunta mediante datos que ya tiene en una tabla pequeña. Según el enfoque de las unidades, debería:

A. Crear un data warehouse para garantizar validez.
B. Adoptar una solución distribuida para facilitar la exploración.
C. Entrenar varios modelos antes de decidir si necesita minería.
D. Comprobar primero si una consulta o visualización resuelve la necesidad.

11. Tenemos cientos de variables numéricas y aplicamos PCA para conservar unas pocas componentes. ¿Qué afirmación es correcta?

A. Las componentes son combinaciones de variables originales y se ordenan por varianza explicada.
B. Las componentes son las columnas originales con mayor capacidad predictiva.
C. La primera componente garantiza la mejor predicción del objetivo.
D. Las componentes son independientes para cualquier distribución de datos.

12. Un sistema utiliza varios servidores dentro de las instalaciones de la empresa y reparte el procesamiento entre ellos. Es:

A. Centralizado y externo.
B. Centralizado e interno.
C. Distribuido e interno.
D. Distribuido y necesariamente alojado en la nube.

13. ¿Qué pregunta puede resolverse directamente mediante agregación, sin inferir un modelo?

A. ¿Qué factores permiten anticipar un impago?
B. ¿Cuál fue el importe medio de los préstamos impagados del año pasado?
C. ¿Qué solicitantes incumplirán sus pagos?
D. ¿Qué perfiles desconocidos de solicitantes aparecen en los datos?

14. Una fuente registra fechas como `03/04/25`, pero unas oficinas usan día/mes/año y otras mes/día/año. ¿Qué actuación es más adecuada?

A. Ordenar las cadenas de texto y cargarlas.
B. Eliminar todas las fechas que tengan ambos números menores que 13.
C. Normalizar numéricamente los dos primeros campos.
D. Determinar la convención de cada origen y transformar a un formato común.

15. ¿Qué combinación representa correctamente los canales visuales?

A. Tono para continente, tamaño para ventas y posición para dos magnitudes numéricas.
B. Tono para ordenar niveles y forma para comparar cantidades con precisión.
C. Tamaño para identificadores y tono para medir distancias exactas.
D. Posición exclusivamente para datos geográficos y luminosidad exclusivamente para categorías nominales.

16. Una empresa elimina nombres de un conjunto de datos y permite que cualquier empleado acceda a él. ¿Qué valoración es correcta?

A. La eliminación de nombres resuelve privacidad y seguridad.
B. Solo debe protegerse si conserva identificadores oficiales.
C. Puede seguir habiendo riesgo de reidentificación y debe controlarse el acceso.
D. El acceso interno garantiza que no hay usos no autorizados.

17. ¿Cuál es la diferencia entre un filter y un wrapper para seleccionar características?

A. Filter utiliza el objetivo y wrapper nunca lo utiliza.
B. Wrapper utiliza un modelo para evaluar selecciones; filter no requiere esa evaluación mediante un modelo.
C. Filter crea componentes nuevas y wrapper conserva columnas originales.
D. Wrapper reduce filas y filter reduce atributos.

18. Un equipo encuentra perfiles de consumo sin etiquetas previas y después llama a los grupos «ocasionales», «frecuentes» e «intensivos». ¿Qué tarea ha realizado?

A. Clasificación ordinal, porque los nombres sugieren un orden.
B. Regresión, porque el consumo se expresa numéricamente.
C. Asociación, porque cada cliente pertenece a un grupo.
D. Clustering, aunque posteriormente se asignen nombres a los grupos.

19. ¿Qué responsabilidad corresponde principalmente al CIO frente al CDO?

A. Dirigir los sistemas y tecnologías de información, frente a gobernar y aprovechar la información como activo.
B. Gobernar el valor de los datos, frente a mantener exclusivamente las bases de datos.
C. Entrenar modelos, frente a desarrollar exclusivamente cuadros de mando.
D. Definir campañas comerciales, frente a administrar exclusivamente servidores.

20. Tras cargar correctamente varias fuentes mediante ETL, ¿qué condición permite considerar preparado el conjunto para minería?

A. Que todas las fuentes sean internas.
B. Que el repositorio contenga todos los campos disponibles.
C. Que los datos estén limpios, seleccionados y formateados para una tarea definida.
D. Que la carga se haya ejecutado en una ventana nocturna.

21. Se quiere comparar con precisión el valor de una misma magnitud entre doce categorías. ¿Qué opción resulta más adecuada según la jerarquía perceptiva estudiada?

A. Esferas con distintos volúmenes.
B. Barras alineadas sobre una base común.
C. Círculos con distintas áreas.
D. Regiones con distintas intensidades de color.

22. Una empresa publica un reto de predicción para que participantes externos propongan soluciones. ¿Qué afirmación es más adecuada?

A. La participación externa elimina la necesidad de coordinar el proyecto.
B. La empresa conserva necesariamente el mismo control que con un equipo propio.
C. La privacidad queda garantizada si hay muchos participantes.
D. El crowdsourcing puede aportar soluciones diversas, pero exige valorar control y exposición de datos.

23. Un registro incorpora datos nuevos cada minuto y corrige los históricos cuando recibe información más fiable. ¿Cómo lo describirías?

A. En flujo y modificable.
B. Estático e incremental.
C. En flujo e incremental, porque crece continuamente.
D. Estático y modificable, porque conserva históricos.

24. En coordenadas paralelas, una línea conecta edad, ingresos, gasto y antigüedad de un cliente. ¿Cómo debe interpretarse?

A. La pendiente expresa cómo evoluciona el cliente con el tiempo.
B. Dos líneas que se cruzan entre ejes corresponden a clientes con algún valor idéntico.
C. Cada cruce con un eje indica el valor del cliente en esa variable, usando la escala de ese eje.
D. La misma altura en todos los ejes significa el mismo valor numérico.

25. Un modelo supera las pruebas técnicas, pero no mejora las decisiones del negocio. ¿Qué actuación encaja mejor con CRISP-DM?

A. Desplegarlo, porque la evaluación técnica ya valida el proyecto completo.
B. Revisar resultados y proceso respecto al objetivo, y decidir si volver a fases anteriores.
C. Aumentar la complejidad del modelo sin revisar el objetivo.
D. Cambiar la infraestructura antes de analizar por qué no aporta utilidad.